Visión Artificial: Propuestas de papers

Integrantes:

>>>>>

- Jhoel Salomon Tapara Quispe
- Hayde Luzmila Humpire Cutipa
- Jair Francesco Huaman Canqui
- Franklin Canaza Ccori

>>>>>

Progressive Growing of GANs for Improved Quality, Stability, and Variation

Describimos una nueva metodología de entrenamiento para redes antagónicas generativas. La idea clave es hacer crecer tanto el generador como el discriminador progresivamente: a partir de una resolución baja, agregamos nuevas capas que modelan detalles cada vez más finos a medida que avanza el entrenamiento. Esto acelera el entrenamiento y lo estabiliza en gran medida, lo que nos permite producir imágenes de una calidad sin precedentes, por ejemplo, imágenes CelebA a 1024^2. También proponemos una forma sencilla de aumentar la variación en las imágenes generadas y lograr una puntuación inicial récord de 8,80 en CIFAR10 sin supervisión. Además, describimos varios detalles de implementación que son importantes para desalentar la competencia malsana entre el generador y el discriminador. Finalmente, sugerimos una nueva métrica para evaluar los resultados de GAN, tanto en términos de calidad de imagen como de variación. Como contribución adicional, construimos una versión de mayor calidad del conjunto de datos de CelebA.

Progressive Growing of GANs for Improved Quality, Stability, and Variation

Comments: Final ICLR 2018 version

Subjects: Neural and Evolutionary Computing (cs.NE); Machine Learning (cs.LG); Machine Learning (stat.ML)

Cite as: arXiv:1710.10196 [cs.NE]

(or arXiv:1710.10196v3 [cs.NE] for this version)

https://doi.org/10.48550/arXiv.1710.10196

Datasets Used



CelebA-HQ

★ introduced in this paper 593 papers also use this dataset



CIFAR-10

11,002 papers also use this dataset



LSUN

633 papers also use this dataset







Progressive Growing of GANs for Improved Quality, Stability, and Variation

https://arxiv.org/abs/1710.10196

HDR image reconstruction from a single exposure using deep CNNs

Los sensores de la cámara solo pueden capturar un rango limitado de luminancia simultáneamente y, para crear imágenes de alto rango dinámico (HDR), generalmente se combina un conjunto de diferentes exposiciones. En este artículo abordamos el problema de predecir la información que se ha perdido en áreas de imagen saturada, para permitir la reconstrucción HDR a partir de una sola exposición. Mostramos que este problema es adecuado para algoritmos de aprendizaje profundo y proponemos una red neuronal convolucional profunda (CNN) que está diseñada específicamente teniendo en cuenta los desafíos en la predicción de valores HDR. Para entrenar la CNN, recopilamos un gran conjunto de datos de imágenes HDR, que aumentamos simulando la saturación del sensor para una variedad de cámaras. Para aumentar aún más la solidez, entrenamos previamente a la CNN en un conjunto de datos HDR simulado creado a partir de un subconjunto de la base de datos MIT Places. Demostramos que nuestro enfoque puede reconstruir resultados HDR visualmente convincentes de alta resolución en una amplia gama de situaciones, y que se generaliza bien para la reconstrucción de imágenes capturadas con cámaras arbitrarias y de gama baja que utilizan funciones de respuesta de cámara desconocidas y posprocesamiento.

HDR image reconstruction from a single exposure using deep CNNs

Comments: Accepted to CVPR 2019 as an oral presentation. Project page at this https URL

Subjects: Computer Vision and Pattern Recognition (cs.CV); Artificial Intelligence (cs.AI); Computational Geometry (cs.CG); Graphics (cs.GR); Robotics (cs.RO)

Cite as: arXiv:1904.07601 [cs.CV]

(or arXiv:1904.07601v3 [cs.CV] for this version)

https://doi.org/10.48550/arXiv.1904.07601

Submission history

From: Yongcheng Liu [view email]

[v1] Tue, 16 Apr 2019 11:28:51 UTC (4,298 KB)

[v2] Mon, 22 Apr 2019 06:56:46 UTC (4,246 KB)

[v3] Sun, 26 May 2019 03:55:11 UTC (4,247 KB)

Datasets Used



ModelNet

1,001 papers also use this dataset



PointCloud-C

17 papers also use this dataset



ModelNet40-C

15 papers also use this dataset







HDR image reconstruction from a single exposure using deep CNNs

https://arxiv.org/abs/1710.07480

Relation-Shape Convolutional Neural Network for Point Cloud Analysis

El análisis de nubes de puntos es muy desafiante, ya que la forma implícita en los puntos irregulares es difícil de capturar. En este documento, proponemos RS-CNN, es decir, Red neuronal convolucional de forma de relación, que extiende la red CNN regular a una configuración irregular para el análisis de nubes de puntos. La clave de RS-CNN es aprender de la relación, es decir, la restricción de topología geométrica entre puntos. Específicamente, el peso convolucional para el conjunto de puntos locales se ve obligado a aprender una expresión de relación de alto nivel a partir de anteriores geométricos predefinidos, entre un punto muestreado de este conjunto de puntos y los demás. De esta forma, se puede obtener una representación local inductiva con un razonamiento explícito sobre la disposición espacial de los puntos, lo que conduce a una gran conciencia de forma y robustez. Con esta convolución como operador básico, RS-CNN, se puede desarrollar una arquitectura jerárquica para lograr un aprendizaje consciente de la forma contextual para el análisis de nubes de puntos. Extensos experimentos sobre puntos de referencia desafiantes en tres tareas verifican que RS-CNN alcanza el estado de la técnica.

Relation-Shape Convolutional Neural Network for Point Cloud Analysis

Comments: Accepted to CVPR 2019 as an oral presentation. Project page at this https URL

Subjects: Computer Vision and Pattern Recognition (cs.CV); Artificial Intelligence (cs.AI); Computational Geometry (cs.CG); Graphics (cs.GR); Robotics (cs.RO)

Cite as: arXiv:1904.07601 [cs.CV]

(or arXiv:1904.07601v3 [cs.CV] for this version)

https://doi.org/10.48550/arXiv.1904.07601

Submission history

From: Yongcheng Liu [view email]

[v1] Tue, 16 Apr 2019 11:28:51 UTC (4,298 KB)

[v2] Mon, 22 Apr 2019 06:56:46 UTC (4,246 KB)

[v3] Sun, 26 May 2019 03:55:11 UTC (4,247 KB)

Datasets Used



ModelNet

1,001 papers also use this dataset



PointCloud-C

17 papers also use this dataset



ModelNet40-C

15 papers also use this dataset







Relation-Shape Convolutional Neural Network for Point Cloud Analysis

https://arxiv.org/abs/1904.07601

